

Sistema de Clasificación de Texto Sobre el Conjunto de Datos

Cómputo de Alto Desempeño (CAD)

Dr. ERNESTO GARCIA AMARO

Jessica Melani Romero Lora (253220116)

Domingo 21 de junio del 2026



Tabla de contenido

1. Objetivo.....	3
2. Desarrollo de la práctica.....	3
2.1 Preprocesamiento y Feature Engineering.....	4
2.2 Clasificación en paralelo.....	6
3. Resultados y Discusión.....	7
3.1 Desempeño comparativo de los modelos.....	7
3.2 Análisis de Errores: matriz de confusión – identificación del mejor modelo: buscando el mejor F1 Macro.....	8
3.3 Aporte de las características no léxicas (sentimiento y entidades).....	8
Conclusión.....	9

1. Objetivo

En la presente actividad se demuestra un sencillo sistema de clasificación de texto a partir de datos pertenecientes al e-commerce, la base de datos agrupa cuatro categorías: electrónica, hogar, libros, ropa y accesorios. En promedio, estas categorías representan el tráfico de alrededor del 80% del comercio electrónico global según reporta *SellersE-Commerce* ([Ecommerce Statistics In 2026 \(Global And U.S. Data\) | SellersCommerce](#)).

Durante la práctica se pretende desarrollar tres estrategias de preprocesamiento y extracción de características, enfocando esfuerzos en la representación léxica mediante *TfidfVectorizer*, posteriormente se realiza análisis de sentimiento mediante *TextBlob* y posteriormente una extracción ordenada de entidades mediante *spaCy*. Este paso final busca enriquecer la representación de texto más allá de la sola frecuencia de términos.

En segundo lugar, se pretende evaluar de manera comparativa tres algoritmos de clasificación supervisada: *RandomForest*, *Regresión Logística* y *SVC*. El objetivo de la evaluación comparativa es identificar el modelo con mejor desempeño bajo las métricas estandarizadas de clasificaciones multiclase.

2. Desarrollo de la práctica

El conjunto de datos original contiene 50, 425 registros con dos columnas: la categoría del producto y una breve descripción textual. Durante esta etapa se realizó una limpieza estructural: eliminación de valores nulos, caracteres faltantes, eliminación de duplicados finalmente la depuración arrojó 27,802 instancias únicamente.

A continuación, se presentan las instancias obtenidas:

Categoría	Instancias (bruto)	Instancias (post-limpieza)
Household	19,313	10,564
Books	11,820	6,256

Electronics	10,621	5,308
Clothing & Accessories	8,671	5,674
Total	50,425	27,802

Tabla 1. Instancias post- depuración

En esta etapa es evidente el desbalance de clases en la base de datos Household concentra el 38.0% del total, mientras que Books posee un 22.5%, Clothing & Accesories representa un 20.40% y Electronics tiene un 19.1%, revelando la naturaleza desproporcionada de la información. A continuación se presenta la etapa de preprocesamiento, la cual evalúa el uso de métricas macro promediadas que ponderan las cuatro clases por igual independientemente de su frecuencia y distribución.

```
$ python3 01_preprocesamiento.py
# ETAPA 1 – PREPROCESAMIENTO Y EXTRACCIÓN DE CARACTERÍSTICAS (paralelo)
[INFO] Dataset cargado: 27802 filas, 4 clases
[INFO] Limpieza textual completada (2.1s)
[INFO] TF-IDF: matriz (27802, 4000) (10.9s)
[INFO] TextBlob sentimiento calculado (18.2s)
      polaridad media=0.1734  subjetividad media=0.4381
[INFO] spaCy entidades extraídas (14.7s)
      entidades/doc promedio: 2.640
[DONE] Etapa de preprocesamiento/extracción finalizada en 48.9s

$ python3 02_clasificacion.py

# ETAPA 2 – CLASIFICACIÓN (RandomForest / LogisticRegression / SVC)
[INFO] Matriz de features final: (27802, 4007) (TF-IDF: 4000 + extra: 7)
[INFO] Clases: ['Books', 'Clothing & Accessories', 'Electronics', 'Household']
[INFO] Train: 22241 Test: 5561
```

2.1 Preprocesamiento y Feature Engineering

Sobre el texto depurado se aplicó una limpieza lingüística básica complementaria: conversión a minúsculas, eliminación de URLs, eliminación de caracteres no alfanuméricos conservando dígitos y puntos decimales (relevantes para conocer las medidas de los productos), eliminación de stopwords así como una normalización de características.

A continuación, se presenta el apartado de entrenamiento y testeo de los modelos.

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42, stratify=y
)

models = {
    "RandomForestClassifier": RandomForestClassifier(
        n_estimators=200, n_jobs=-1, random_state=42),
    "LogisticRegression": LogisticRegression(max_iter=2000, C=5.0),
    "SVC (kernel lineal)": LinearSVC(C=1.0, max_iter=5000, dual=True),
}

for name, clf in models.items():
    clf.fit(X_train, y_train)
    y_pred = clf.predict(X_test)
    print(classification_report(y_test, y_pred, target_names=le.classes_, digits=4))
```

Por otra parte, de manera paralela, se definieron tres rutas de extracción de características:

1. TfidfVectorizer – representación léxica

Se construyó una matriz TF-IDF de unigramas y bigramas, con un vocabulario acotado de 4,000 términos y una frecuencia mínima de documento (min_df) de 3 para descartar ruido léxico de baja frecuencia. Esta representación es capaz de capturar las palabras y combinaciones de palabras más discriminantes de la categoría; los términos con mayor frecuencia acumulada fueron: cotton, set, black, size, made, women, quality y color. Esto sugiere que existen separaciones claras entre las características de la ropa como composición, público objetivo y color.

2. TextBlob – análisis de sentimiento

Para cada descripción se calcularon dos descripciones: polaridad (rango -1 a 1, tono negativo/ positivo del texto) y subjetividad (rango de 0 a 1, grado de opinión frente a hecho objetivo). El corpus completo mostró una polaridad media de 0.1734, consistente con el tono mayoritariamente promocional y positivo de las descripciones de producto, y una subjetividad media de 0.4381,

reflejando una mezcla de afirmaciones objetivas (materiales, dimensiones) y subjetivas (calidad, estética).

3. spaCy – extracción de identidades

El entorno de ejecución utilizado no contó con el acceso a red para descargar el modelo estadístico preentrenado de spaCy (`en_core_web_sm`); las categorías genéricas de dicho modelo fueron persona, organización y lugar, además de poco informativas para conocer más sobre el producto, las entidades son prácticamente inexistentes. Debido a esto, se optó por construir, sobre el motor de spaCy utilizando el tokenizador y el matcher, un componente de extracción de entidades basado en reglas, diseñado específicamente para el dominio del comercio electrónico con cuatro tipos de entidad: medidas (patrones numéricos seguidos de unidades como inch, cm, kg, ml), cantidad (expresiones como “set de 4” o “6 piezas”), material (léxico cerrado: algodón, piel, sintético – plásticos, madera, lana). En promedio, se detectaron 2.64 entidades por descripción, siendo material y color las más frecuentes en las categorías de Ropa y Accesorios, así como en Hogar. Las tres rutas de extracción se ejecutaron sobre el mismo texto base y sus salidas se persistieron por separado, lo que permite que la siguiente etapa las combine libremente en una sola matriz de características.

2.2 Clasificación en paralelo

A diferencia de un enfoque que utilizara únicamente la matriz TF-IDF, en este trabajo la matriz de entrada a los clasificadores combina las tres fuentes de características generadas en la etapa anterior: las 4,000 dimensiones léxicas de TF-IDF más las dos puntuaciones de sentimiento (polaridad, subjetividad) y las cuatro cuentas de entidades por documento (medida, cantidad, material, color), estas últimas estandarizadas (media 0, varianza 1) antes de concatenarse con la matriz dispersa de TF-IDF. La matriz final tiene 4,007 columnas por las 27,802 instancias del corpus depurado.

El conjunto se dividió en entrenamiento – 80% equivalente a 22,241 instancias y testeo 20% – 5, 561 instancias mediante muestreo estratificado, preservando la proporción de clases en ambos subconjuntos. Sobre esta partición se entrenaron y evaluaron de manera paralela los algoritmos solicitados:

- RandomForest: 200 árboles, sin profundidad máxima fija, paralelizado entre núcleos.
- LogisticRegression: regularización L2 (C= 5.0), 2,00 iteraciones máximas, esto se resolvió por defecto multinomial.
- SVC: tomando en cuenta el volumen del corpus, un SVC con kernel no lineal (rbf) resulta computacionalmente inviable por su complejidad cuadrática a cúbica en el número de instancias. Por lo que se utilizó la formulación de margen máximo lineal (LinearSVC, optimizada vía liblinear) equivalente a un SVC de kernel lineal pero escalable a este volumen de datos.

Para cada modelo se midieron exactitud – accuracy, precisión – precision, recall y F1 Score macro promediados (es decir, calculados por clase y promediados sin ponderar por frecuencia, para no favorecer a la clase mayoritaria de Hogar), además de la matriz de confusión y el tiempo de entrenamiento.

3. Resultados y Discusión

3.1 Desempeño comparativo de los modelos

A continuación se presentan los resultados de los tres clasificadores sobre el conjunto de pruebas (5, 561 instancias).

Modelo	Accuracy	Precisión (macro)	Recall (macro)	F1 (macro)	Tiempo (s)
SVC (kernel lineal)	0.9491	0.9502	0.9471	0.9486	22.9

Regresión Logística	0.9468	0.9492	0.9440	0.9465	2.0
Random Forest	0.9257	0.9317	0.9210	0.9259	62.1

Tabla 2. Desempeño de clasificadores sobre el conjunto de prueba

Como podemos observar, el desempeño de las métricas de los tres algoritmos oscila en valores similares, sin embargo, Regresión Logística registra un F1-Macro de 0.9465 manteniendo una diferencia de 0.21 puntos respecto al SVC, esto resulta interesante porque solo requiere 2.0 segundos de procesamiento en comparación con los 22.9 segundos que necesita SVC para realizar la clasificación.

Por otra parte, Random Forest registró un desempeño F1-Macro de 0.9259 además de un performance de 62.1 segundos en tiempo de ejecución. Este costo es computacionalmente alto sin embargo, coincide con la naturaleza de la clasificación del proceso de bosques aleatorios. La ventaja frente a modelos lineales tiene que ver con las relaciones no lineales entre características, mientras que en espacios de alta dimensionalidad y dispersión como TF-IDF aquellos clasificadores lineales (SVC, Regresión Lineal) superan a los métodos de ensamble basados en árboles.

```

=====
[MODELO] RandomForestClassifier (entrenado en 58.5s)
  Accuracy : 0.9257  Precision(macro): 0.9317  Recall(macro): 0.9210  F1(macro): 0.9259
=====

```

	precision	recall	f1-score	support
Books	0.9337	0.9113	0.9223	1251
Clothing & Accessories	0.9551	0.9568	0.9560	1135
Electronics	0.9362	0.8710	0.9024	1062
Household	0.9016	0.9451	0.9228	2113
accuracy			0.9257	5561
macro avg	0.9317	0.9210	0.9259	5561
weighted avg	0.9263	0.9257	0.9256	5561

```

=====
[MODELO] LogisticRegression (entrenado en 1.5s)
  Accuracy : 0.9468  Precision(macro): 0.9492  Recall(macro): 0.9440  F1(macro): 0.9465
=====

```

	precision	recall	f1-score	support
Books	0.9500	0.9257	0.9377	1251
Clothing & Accessories	0.9779	0.9744	0.9762	1135
Electronics	0.9338	0.9162	0.9249	1062
Household	0.9350	0.9598	0.9472	2113
accuracy			0.9468	5561
macro avg	0.9492	0.9440	0.9465	5561
weighted avg	0.9469	0.9468	0.9467	5561

```

=====
[MODELO] SVC (kernel lineal) (entrenado en 15.7s)
  Accuracy : 0.9491  Precision(macro): 0.9502  Recall(macro): 0.9471  F1(macro): 0.9486
=====

```

	precision	recall	f1-score	support
Books	0.9518	0.9313	0.9414	1251
Clothing & Accessories	0.9763	0.9780	0.9771	1135
Electronics	0.9305	0.9209	0.9257	1062
Household	0.9423	0.9584	0.9503	2113
accuracy			0.9491	5561
macro avg	0.9502	0.9471	0.9486	5561
weighted avg	0.9491	0.9491	0.9491	5561

```

=====
RESUMEN COMPARATIVO – DESEMPEÑO SOBRE EL CONJUNTO DE PRUEBA
=====

```

	Accuracy	Precision_macro	Recall_macro	F1_macro	Tiempo_s
SVC (kernel lineal)	0.9491	0.9502	0.9471	0.9486	15.68
LogisticRegression	0.9468	0.9492	0.9440	0.9465	1.51
RandomForestClassifier	0.9257	0.9317	0.9210	0.9259	58.52

```

[CONCLUSION] Mejor modelo según F1-macro: SVC (kernel lineal) (F1=0.9486)
[DONE] Etapa de clasificación finalizada en 78.6s

```

3.2 Análisis de Errores: matriz de confusión – identificación del mejor modelo: buscando el mejor F1 Macro

En este apartado se presenta la matriz de confusión del SVC, buscando el mejor desempeño específicamente en la métrica F1 – Macro:

Real \ Predicho	Libros	Ropa	Electrónica	Hogar
Libros	1165	10	25	51
Ropa	5	1110	7	13
Electrónica	20	4	978	60
Hogar	34	13	41	2025

Tabla 3. Desempeño de clasificadores sobre el conjunto de prueba

El patrón de error dominante es la confusión bidireccional entre Electronics y Household: 60 instancias reales de Electronics se clasificaron como Household y 41 instancias reales de Household se clasificaron como Electronics. Este resultado es coherente con el contenido del catálogo, donde abundan productos híbridos como electrodomésticos de cocina, ventiladores o lámparas, cuyo vocabulario de producto (material, tamaño, uso doméstico) se superpone considerablemente entre ambas categorías.

En contraste, Clothing & Accessories presentó la mayor separabilidad (precision 0.9763, recall 0.9780 para el SVC), lo cual es explicable por un vocabulario muy distintivo (cotton, size, women, men, fabric) capturado eficazmente por TF-IDF y reforzado por las entidades de tipo MATERIAL y COLOR.

3.3 Aporte de las características no léxicas (sentimiento y entidades)

Si bien la separabilidad de las clases está dominada por la representación TF-IDF —dado que el vocabulario de producto es, por construcción, altamente

discriminante entre categorías—, las características de sentimiento y entidades aportan una señal complementaria y marginal. En el análisis de importancia de variables del RandomForestClassifier, la cuenta total de entidades (ent_total) y la subjetividad (sent_subjectivity) se ubicaron entre las quince variables más relevantes del modelo, por debajo de los términos léxicos más frecuentes pero por encima de la mayoría de los bigramas de baja frecuencia. Esto sugiere que dichas características podrían tener mayor impacto relativo en escenarios con vocabulario más ambiguo o en tareas de clasificación de grano más fino (por ejemplo, subcategorías dentro de Household), lo cual queda como línea de trabajo futuro.

Conclusión

Durante el desarrollo de esta práctica identifiqué que es posible alcanzar un desempeño de clasificación superior al 94% de exactitud realizando una combinación de usando TF– IDF utilizando unigramas y bigramas mediante la identificación de características semánticas derivadas de análisis de sentimiento mediante TextBlob y de entidades de dominio spaCy.

Durante la realización de este ejercicio logré identificar las principales fortalezas de los algoritmos evaluados, durante esta etapa observé que Regresión Logística registró el mejor desempeño a nivel computacional y mantuvo excelentes resultados con la métrica global F1 – Macro. (0.9465). Mientras que SVC de kernel lineal representó el algoritmo más costoso con un procesamiento de 22.9 segundos y una excelente puntuación en F1 – Macro (0.9486). Por su parte, Random Forest no logró igualar el desempeño de sus competidores, manteniendo las métricas más bajas en los 4 rubros evaluados.

El principal reto de clasificación identificado es la frontera semántica entre las categorías Electronics y Household, donde el vocabulario de producto se superpone de forma natural en la descripción de los artículos pertenecientes a los electrodomésticos y artículos eléctricos de uso doméstico; este hallazgo sugiere que



una mejora futura podría buscar características adicionales específicas (por ejemplo, presencia de términos relacionados con electricidad o alimentación eléctrica) o una jerarquía de clasificación en dos niveles para discriminar mejor estos casos límite.